EXPLORER LES TEXTES À L'ÈRE DU NUMÉRIQUE

Qui a déjà entendu parler, vu ou pratiqué un langage à balises comme HTML ou XML ?

PARTIE 1

XML et la structuration des documents

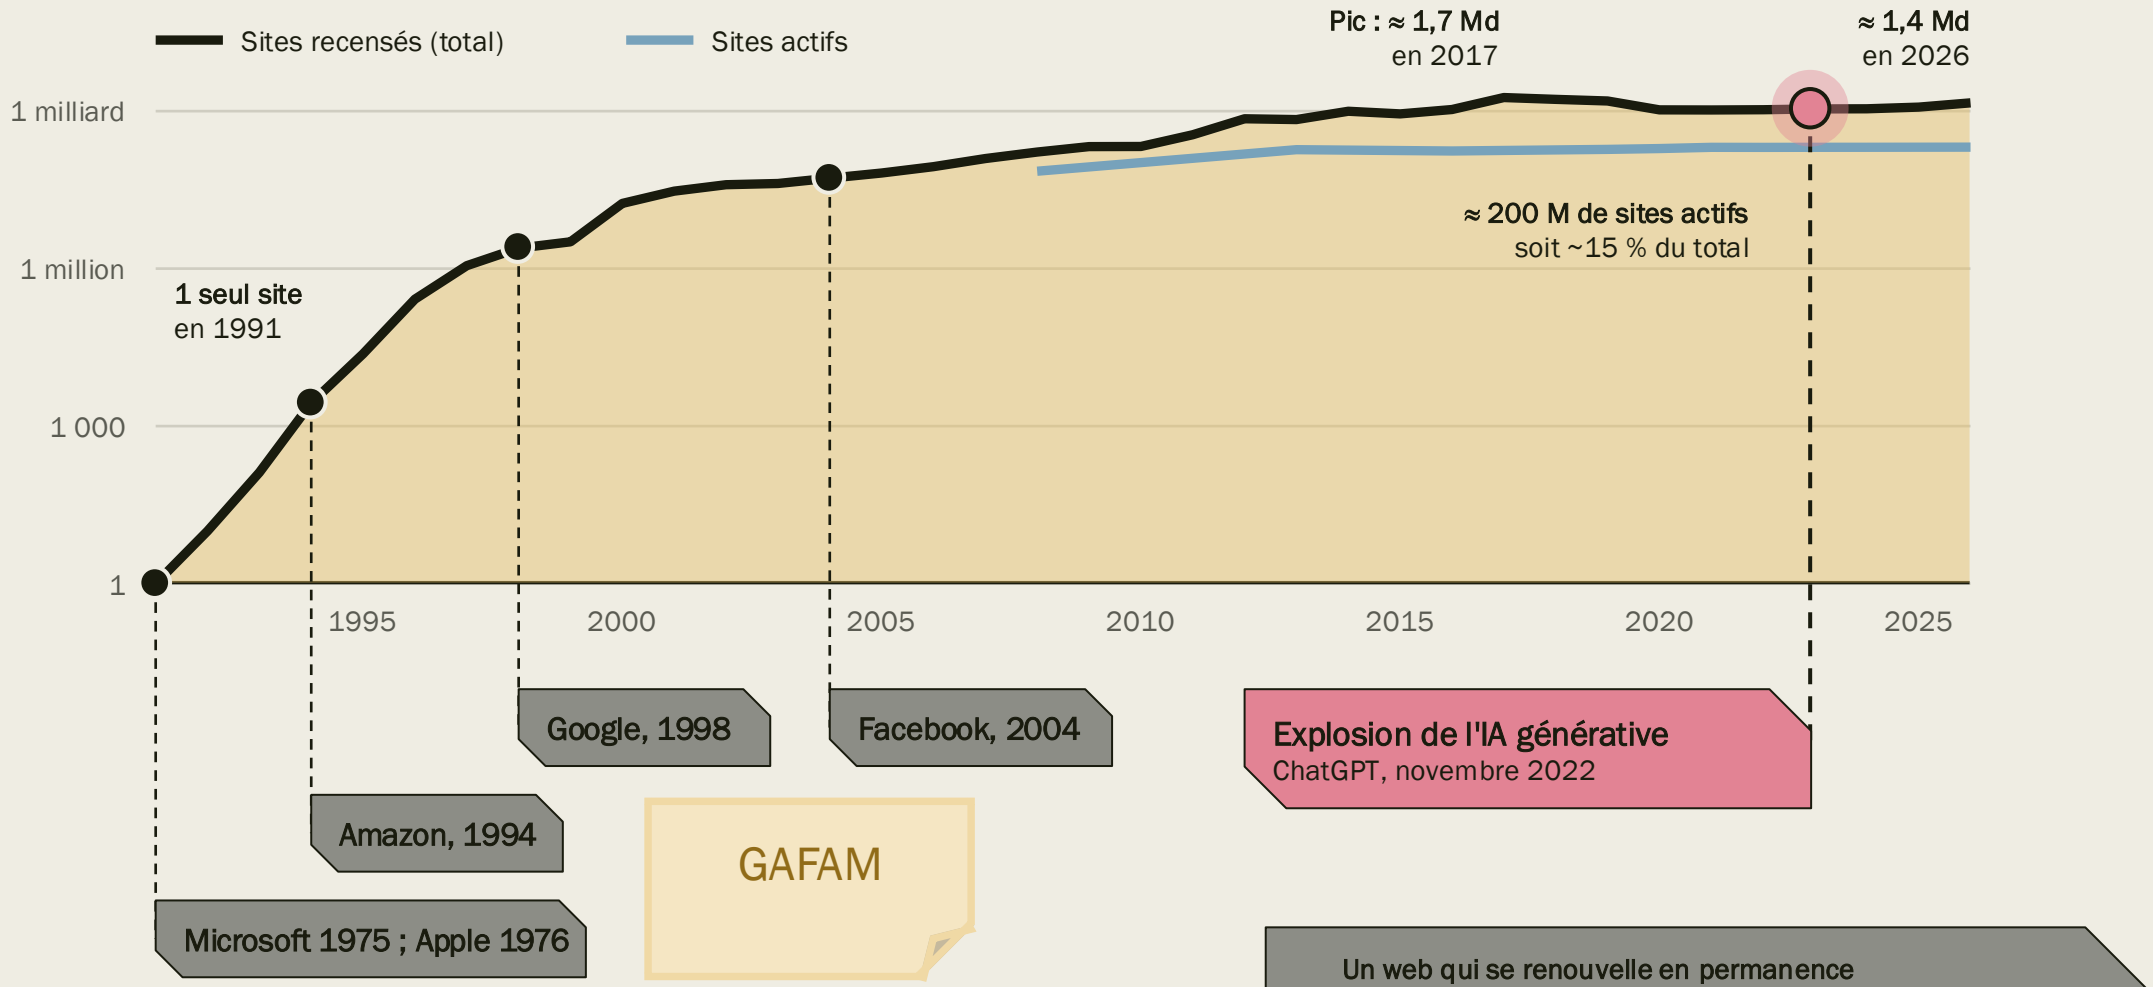
ORIGINES : DEUX LANGAGES, UNE HISTOIRE DU WEB

XML et HTML

Origines

- HTML
  - *Fin des années 1980*
  - *Tim Berners-Lee au CERN (1989)*
  - *Flexible*
  - ***Visualiser des données***
- XML
  - *Échanger des informations entre les systèmes hétérogènes*
  - *1996 et recommandation par le W3C en 1998*
  - *Rigoureux*
  - *Transformable vers du HTML avec des fiches XSLT*
  - ***Structurer des données***

Évolution du nombre de sites internet depuis la creation du web



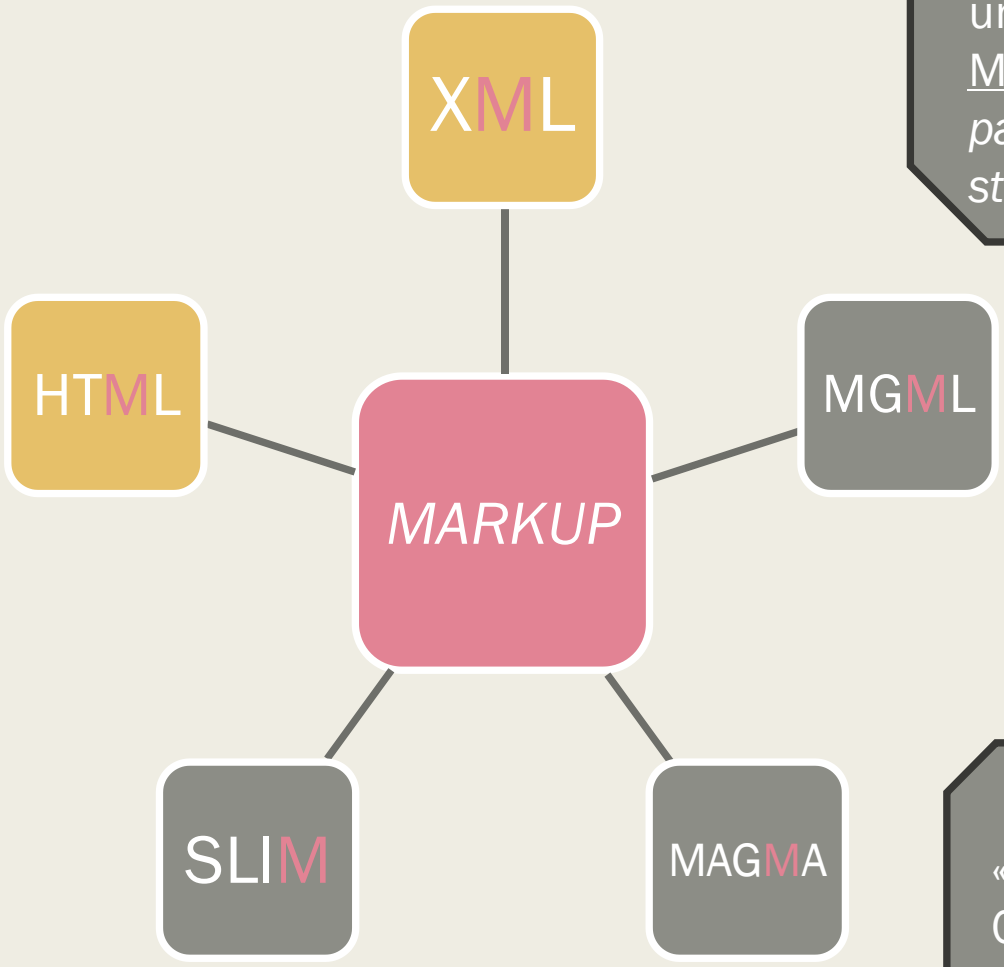
Un web qui se renouvelle en permanence
Chaque jour, des centaines de milliers de sites naissent (252 000 à 1,25 M selon les sources) ; d'autres expirent ou sont abandonnés.

Sources : Internet Live Stats, Netcraft, Siteefy, CERN.
Cette diapositive est mise en forme par IA

Origines

- HTML
  - *Fin des années 1980*
  - *Tim Berners-Lee au CERN (1989)*
  - *Flexible*
  - ***Visualiser des données***
- XML
  - *Échanger des informations entre les systèmes hétérogènes*
  - *1996 et recommandation par le W3C en 1998*
  - *Rigoureux*
  - *Transformable vers du HTML avec des fiches XSLT*
  - ***Structurer des données***

Origines



DÉFINITIONS :

TEXTE : « Suite de signes linguistiques constituant un écrit ou une œuvre » (*CNRTL*)
MARKUP : « *A text containing semantic markup is effectively a parallel text between human language and semantic structures.* » (*Cambridge English Corpus*)

« le chat » pour un ordinateur est : « 01101100 01100101 00100000 01100011 01101000 01100001 01110100 »

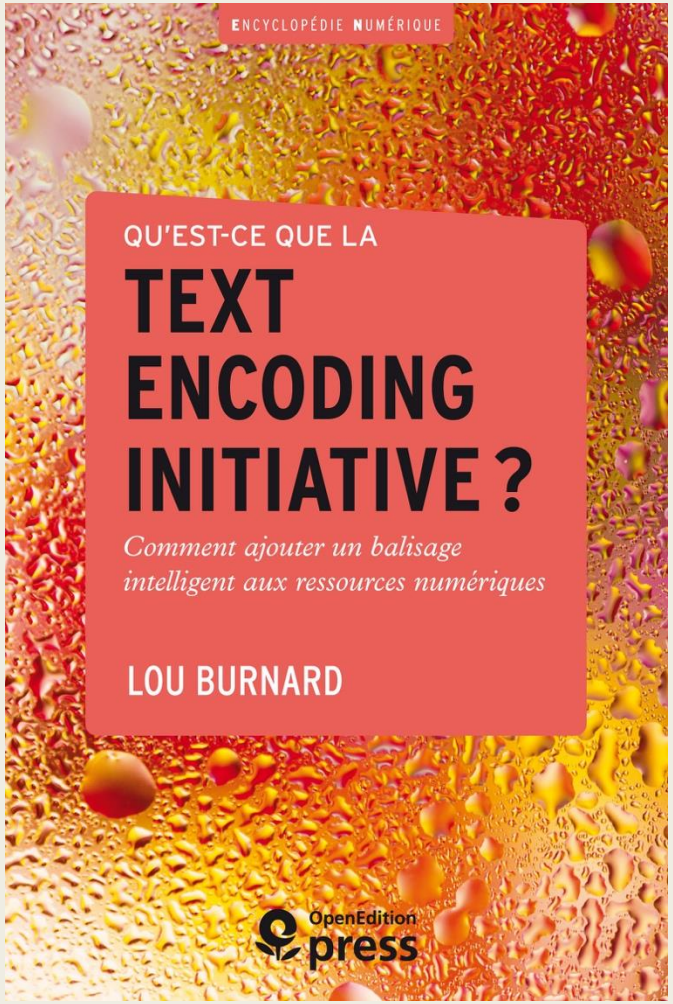
STANDARDISER

XML-TEI

À votre avis, au regard de ce que nous venons de voir, pourquoi les chercheurs ont-ils besoin de s'appuyer sur un standard commun pour encoder leurs sources en XML ?

Standardiser : les principes de la TEI

- TEI : *Text Encoding Iniative*
  - *Standard établit par un consortium initié par Lou Burnard en 1987 (initialement adapté pour le SGML)*
  - *Un ctrl+f ne suffit plus pour différencier le sens des homographes*
  - *Il faut pouvoir décrire des structures plus finement*



Burnard, Lou. *Qu'est-ce que la Text Encoding Initiative ?* Traduit par Marjorie Burghart. Marseille: OpenEdition Press, 2015. doi:10.4000/books.oep.1237.

Standardiser : les principes de la TEI

« des **paris** ont été faits que **paris** partirait de **paris** pour aller à **paris** » (avec ctrl+f : « paris » apparait 4 fois => **Le numérique n'a pas compris le sémantisme de chaque mot**)

Solution de la TEI : 4 « paris » au sémantisme différents par l'ajout d'attributs et de balises définies

- <w lemma="pari" pos="NOMcom » > paris </w>
- <persName nymRef="#paris_hilton"> paris </persName>
- <placeName type="city" where="france" subtype="capital"> paris </placeName>
- <placeName type="city" where="usa"> paris </placeName>

ENCODER UN TEXTE

Règles de bonne pratique

Encoder : règles sur les balises

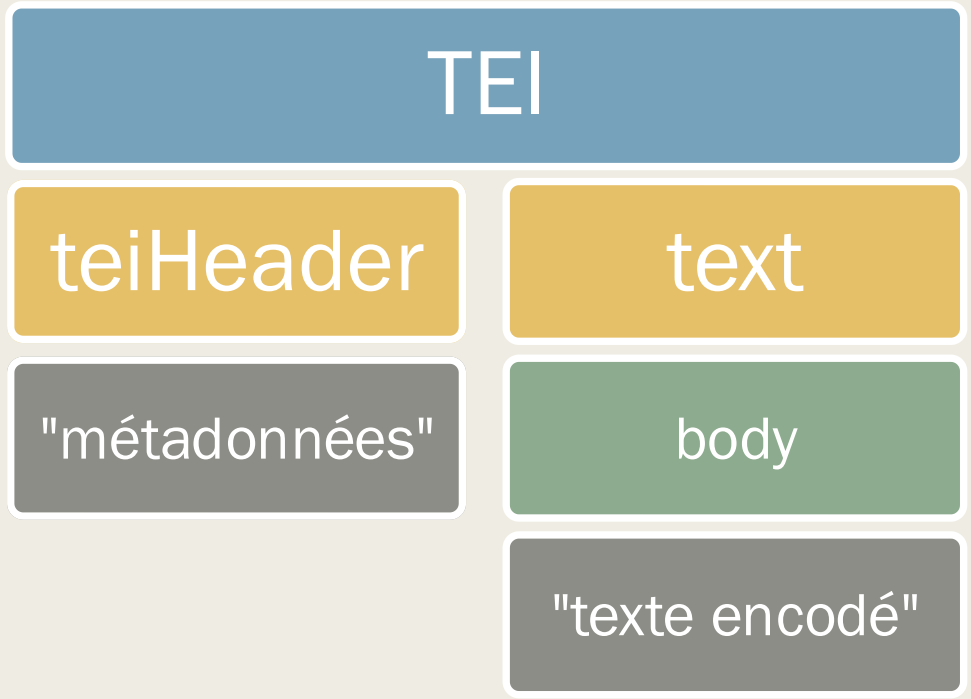
- Une balise est indiquée par des chevrons *enfermant* le nom de la balise :
- Chaque balise ouvrante doit avoir une balise fermante. Ces deux balises *emballent* la donnée : ex. <persName> Paris Hilton </persName>
- Les balises peuvent s'imbriquer, mais elles ne peuvent pas se chevaucher
  - 👎 ces balises se <w> chevauchent </w>
  - 👍 ces balises ne se <w>chevauchent</w> pas
- Les noms de balises sont sensibles à la casse <nom> =/= <Nom>
- Un élément vide ne possède qu'une balise auto-fermante : <photo/>
- Certains caractères sont réservés à XML et ne peuvent pas être présents dans le texte '&', '<', '>' (on les remplace par '&' '<' '>')
- Un document XML commence par la balise d'instruction (placée d'office par les éditeurs de code) : <?xml version="1.0" encoding="utf-8"?>
- Il est possible d'ajouter des attributs dans les balises. Ils se placent alors DANS la balise ouvrante : <date when=''1789-07-14''> le 14 juillet 1789 </date>

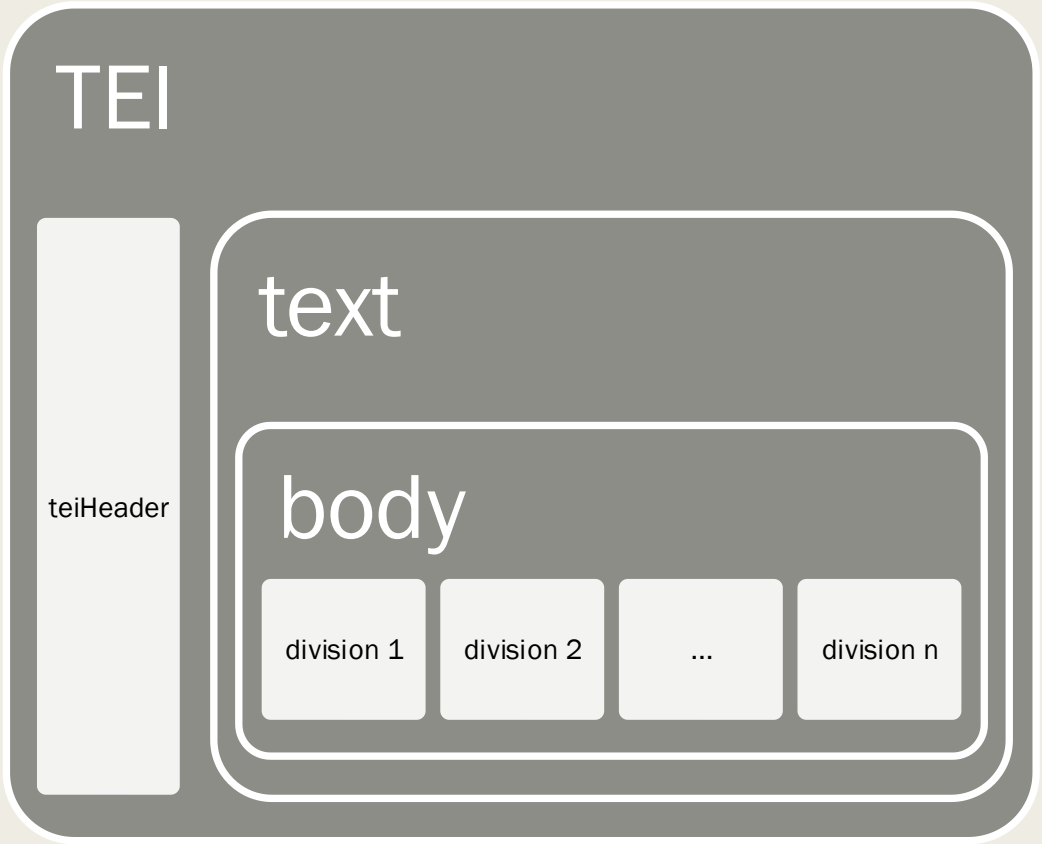
Encoder : règles de la TEI

- Après la balise d'instruction, on déclare la racine du document avec son espace de nom comme étant : <TEI xmlns="http://www.tei-c.org/ns/1.0"> (elle se referme en </TEI> à la toute fin du document => elle emballe TOUT)
- Le document se divise en deux parties :
  - <teiHeader> : qui comporte toutes les informations sur le texte de l'auteur à l'encodeur en passant par la description de la source
  - <text> : elle s'ouvre **après** le </teiHeader> et comporte une balise <body> qui est le corps du texte que nous allons encoder. Tout le contenu sera dans ces deux dernières balises

Encoder : règles sur la TEI

- La structure est alors la suivante (les deux visualisations sont identiques mais celle de droite montre l'emboîtement, quant à celle de gauche la hiérarchie est plus compréhensible)

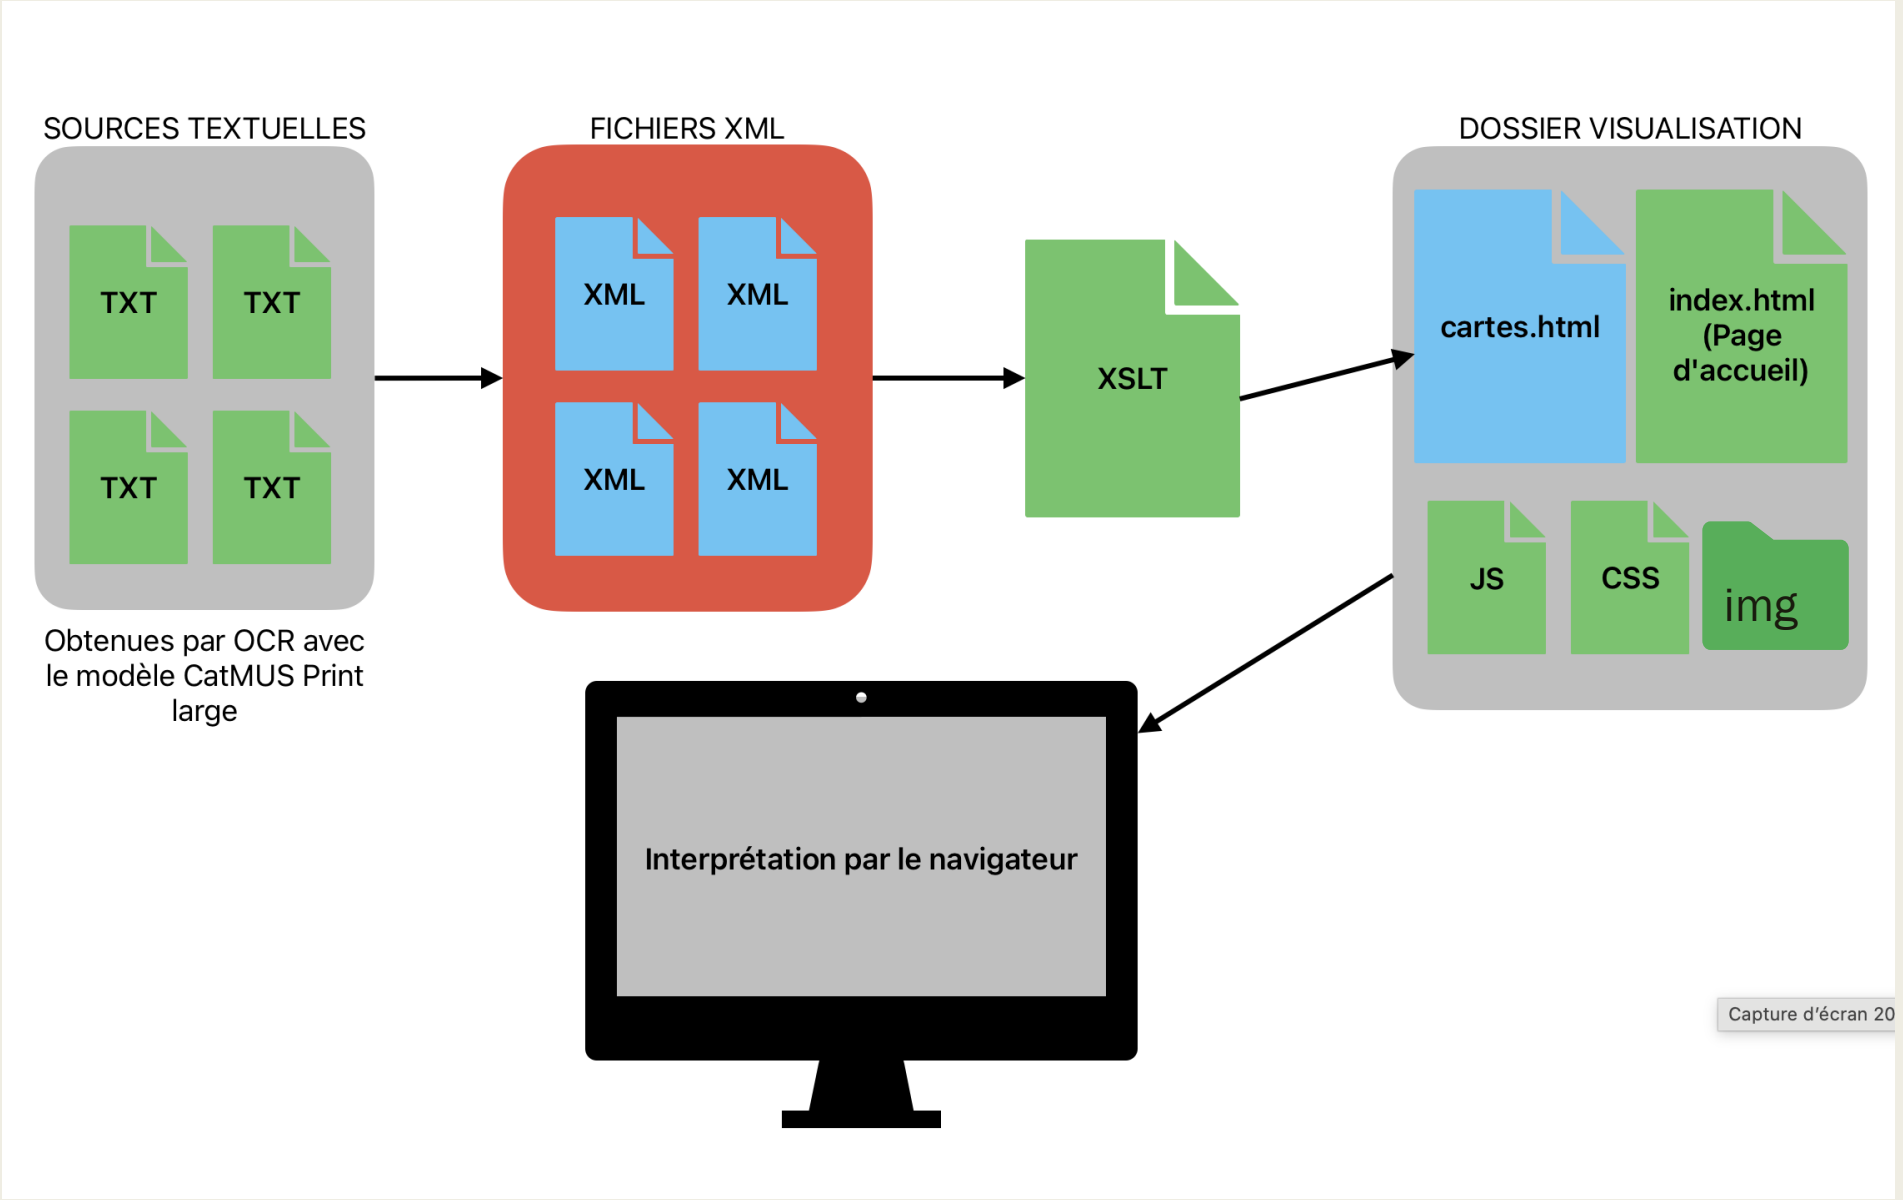




PRATIQUE COLLECTIVE

Etablir l’encodage : Perrault et Rigaud

Chaîne éditoriale suivie aujourd'hui



En bleu sont les fichiers que vous allez créer. En vert, ceux qui sont déjà prêts et qui vont coexister dans l'environnement.

Pratique

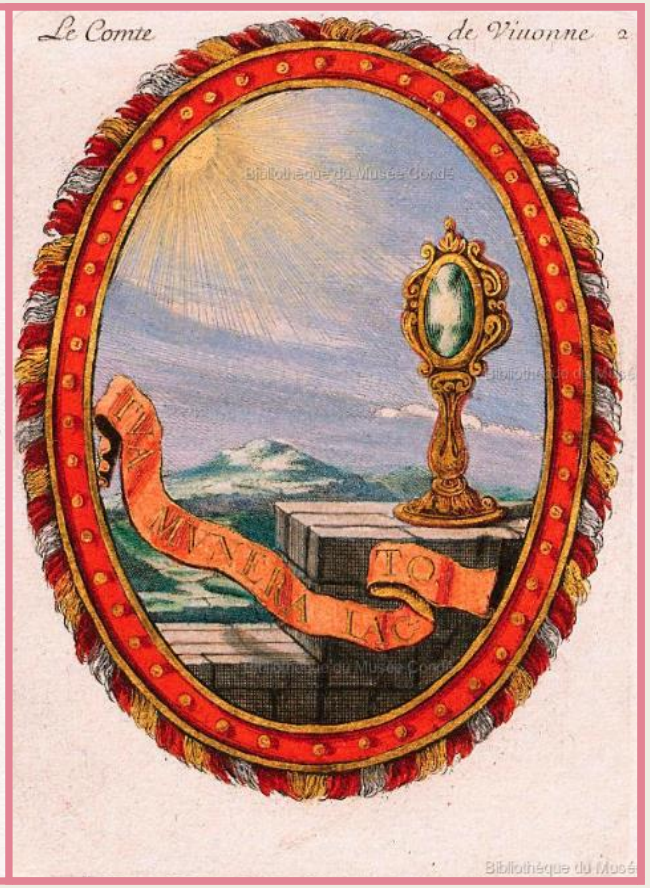
II. DEVISE
DV
COMTE DE VIVONNE.

Vn Miroir ardant.

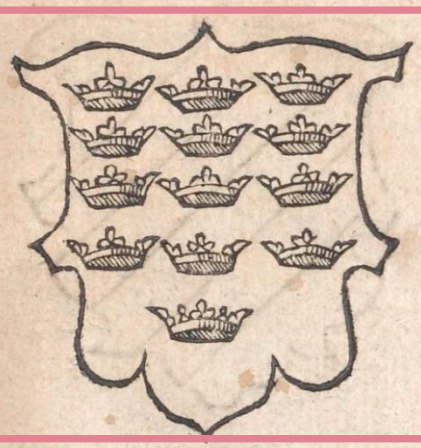
TVA MVNERA JACTO.

Ie répans tes preſens.

Le Miroir ardant loin de renfermer en luy-méme la lumiere du Soleil, la refléchit, & la renvoye de toutes parts avec encore plus de force qu'elle ne luy eſt envoyée, & de cette ſorte il eſt le ſymbole parfait de la reconnoiſſance de ce Chevalier pour les bienfaits qu'il a receus de Sa Majeſté, qu'il s'efforce de faire éclater en tous lieux & en toutes rencontres.



Le Roy Artus.



Le Roy Artus portoit en ſes armes d'Azur à treize courõnes d'or. Il fut grand conquerant, & fit nobles & vaillantes prouëſſes. Il inſtitua l'ordre de la table rõde au pays de la grãd Bretaigne, à laquelle deuoyent comparoir vne fois l'an, au iour de la Pentecoſte, tous les chevaliers errans.

Pratique

5 éléments :

- : la structure entière (description + image)
- <head> : le titre de l'armoirie
- <figure> qui emballe <graphic/> : contenant le lien vers l'image à lier
- <p> : le paragraphe de description

COMMENT L'ORGANISER EN XML ?



Pratique

```
<div type="personnage" xml:id="p-arthur">
    <head>Roy Artus</head>

    <figure xml:id="img-arthur">
        <graphic url="img/A1.png"/>
    </figure>

    <p type="description"> Le Roy Artus portoit en ses armes d'Azur à treize couronnes
        d'or. Il fut grand conquerant, et fit nobles et vaillantes prouësses. Il
        institua l'ordre de la table ronde au pays de la grand Bretaigne, à laquelle
        devoyent comparoir une fois l'an, au jour de la Pentecoste, tous les chevaliers
        errans. </p>
</div>
```



Structure commune

```
    <div type="personnage" xml:id="p-REMPLACER">
    <head> REMPLACER </head>

    <figure xml:id="img-REMPLACER">
        <graphic url="img/REMPLACER.png"/>
    </figure>

    <p type="description"> REMPLACER </p>
</div>
```

Pratique

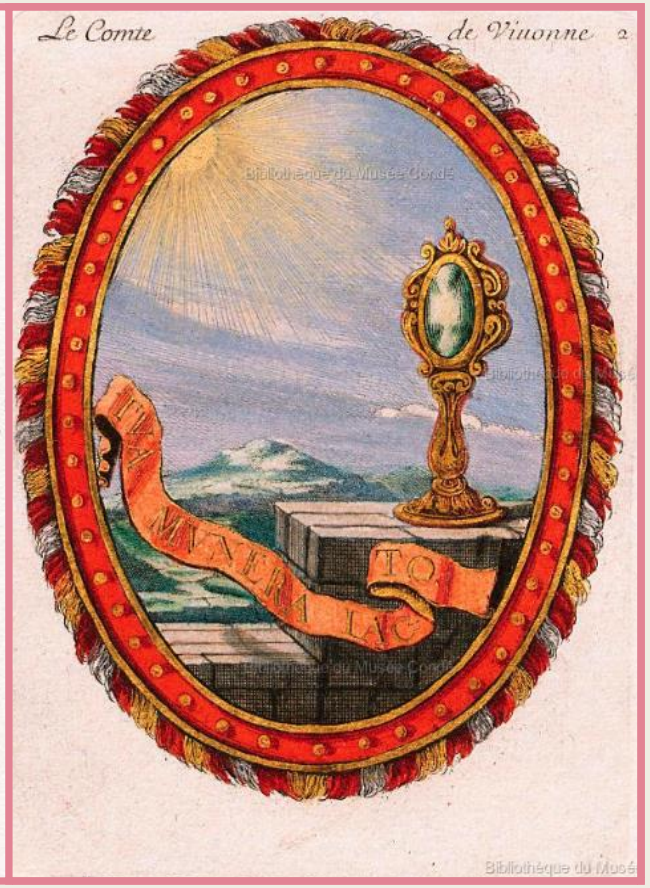
II. DEVISE
DV
COMTE DE VIVONNE.

Vn Miroir ardant.

TVA MVNERA JACTO.

Ie répans tes preſens.

Le Miroir ardant loin de renfermer en luy-méme la lumiere du Soleil, la reflé-chit, & la renvoye de toutes parts avec encore plus de force qu'elle ne luy eſt en-voyée, & de cette ſorte il eſt le ſymbole parfait de la reconnoiſſance de ce Cheva-lier pour les bienfaits qu'il a receus de Sa Majeſté, qu'il s'efforce de faire éclater en tous lieux & en toutes rencontres.

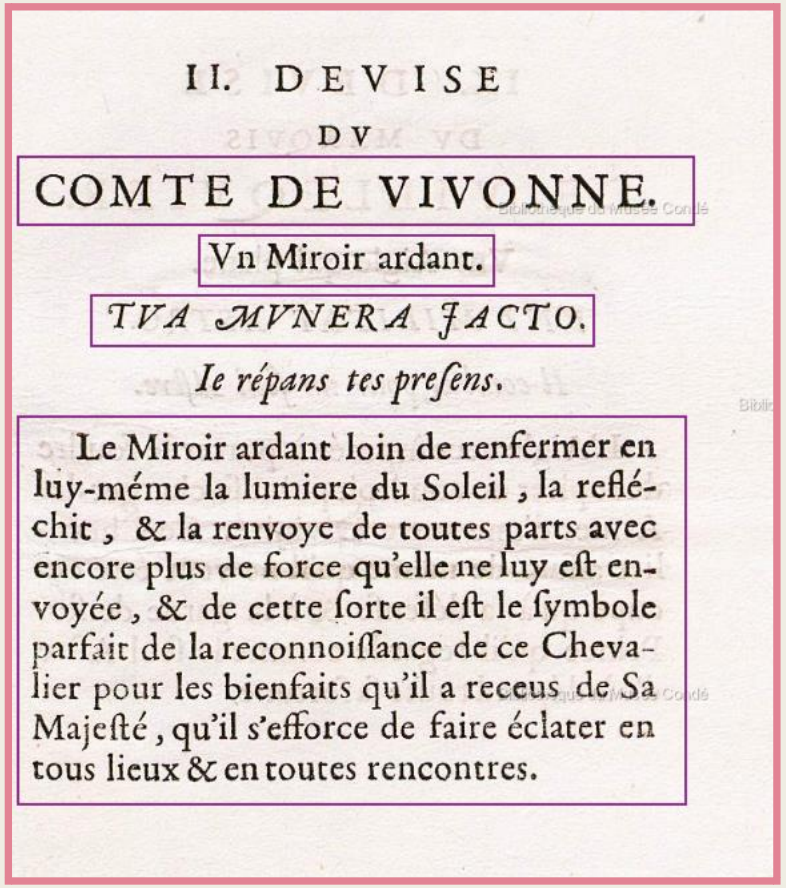


7 éléments :

- : la structure entière (description + image)
- <head> : le titre de l'armoirie
- <figure> qui emballe <graphic/> : l'image à lier; et <figDesc> : la description de l'image
- <q> : la citation extraite de l'image
- <p> : le paragraphe de description

COMMENT L'ORGANISER EN XML ?

Pratique



II. DEVISE
DV
COMTE DE VIVONNE.

Vn Miroir ardant.

TVA MVNERA JACTO.

Ie répans tes preſens.

Le Miroir ardant loin de renfermer en luy-méme la lumiere du Soleil, la refléchit, & la renvoye de toutes parts avec encore plus de force qu'elle ne luy eſt envoyée, & de cette ſorte il eſt le ſymbole parfait de la reconnoiſſance de ce Chevalier pour les bienfaits qu'il a receus de Sa Majeſté, qu'il s'efforce de faire éclater en tous lieux & en toutes rencontres.

```
<div type="personnage" xml:id="p-vivonne">

    <head> COMTE DE VIVONNE </head>

    <figure xml:id="img-vivonne">
        <graphic url="img/0102.png"/>
        <figDesc> Un Miroir ardant </figDesc>
    </figure>

    <q type="devise" xml:lang="la"> TUA MUNERA JACTO </q>
    <p type="description"> Le Miroir ardant loin de renfermer en luy-méme la lumiere
        du Soleil, la refléchit, et la renvoye de toutes parts avec encore plus de
        force qu'elle ne luy est envoyée, et de cette sorte il est le symbole
        parfait de la reconnoissance de ce Chevalier pour les bienfaits qu'il a
        receus de Sa Majesté, qu'il s'efforce de faire éclater en tous lieux et en
        toutes rencontres. </p>
</div>
```

Structure commune

```
<div type="personnage" xml:id="p-REMPLACER">

    <head> REMPLACER </head>

    <figure xml:id="img-REMPLACER">
        <graphic url="img/REMPLACER.png"/>
        <figDesc> REMPLACER </figDesc>
    </figure>

    <q type="devise" xml:lang="la"> REMPLACER </q>
    <p type="description">
        REMPLACER
    </p>
</div>
```

C’EST PARTI !

Encodons !

- Récupérer le sur mon GitHub : voir signature de mail puis « Workshop2026 »
  - *Dans « Code » faire « Télécharger le ZIP » (le décompresser dans un répertoire de travail pour aujourd'hui)*
- Aller sur *XML Online Viewer* et importer le fichier sur lequel vous travaillez
  - *L'encoder en fonction de ce que nous venons de mettre en place*
  - *Commencer par le faire à la main pour comprendre comment fonctionne la structure ; puis prendre la structure à remplir (l'annotation respecte une structure commune donc reproductible au besoin)*
- Une fois l'encodage fait
  - *Exporter le fichier et le renommer À L'IDENTIQUE*
- Me l'envoyer par mail : lucas.favier@univ-lyon3.fr

Perrault

```
<div type="personnage" xml:id="p-REMPLACER">

    <head> REMPLACER </head>

    <figure xml:id="img-REMPLACER">
        <graphic url="img/REMPLACER.png"/>
        <figDesc> REMPLACER </figDesc>
    </figure>

    <q type="devise" xml:lang="la"> REMPLACER </q>
    <p type="description">
        REMPLACER
    </p>
</div>
```

Rigaud

```
    <div type="personnage" xml:id="p-REMPLACER">
    <head> REMPLACER </head>

    <figure xml:id="img-REMPLACER">
        <graphic url="img/REMPLACER.png"/>
    </figure>

    <p type="description"> REMPLACER </p>
</div>
```

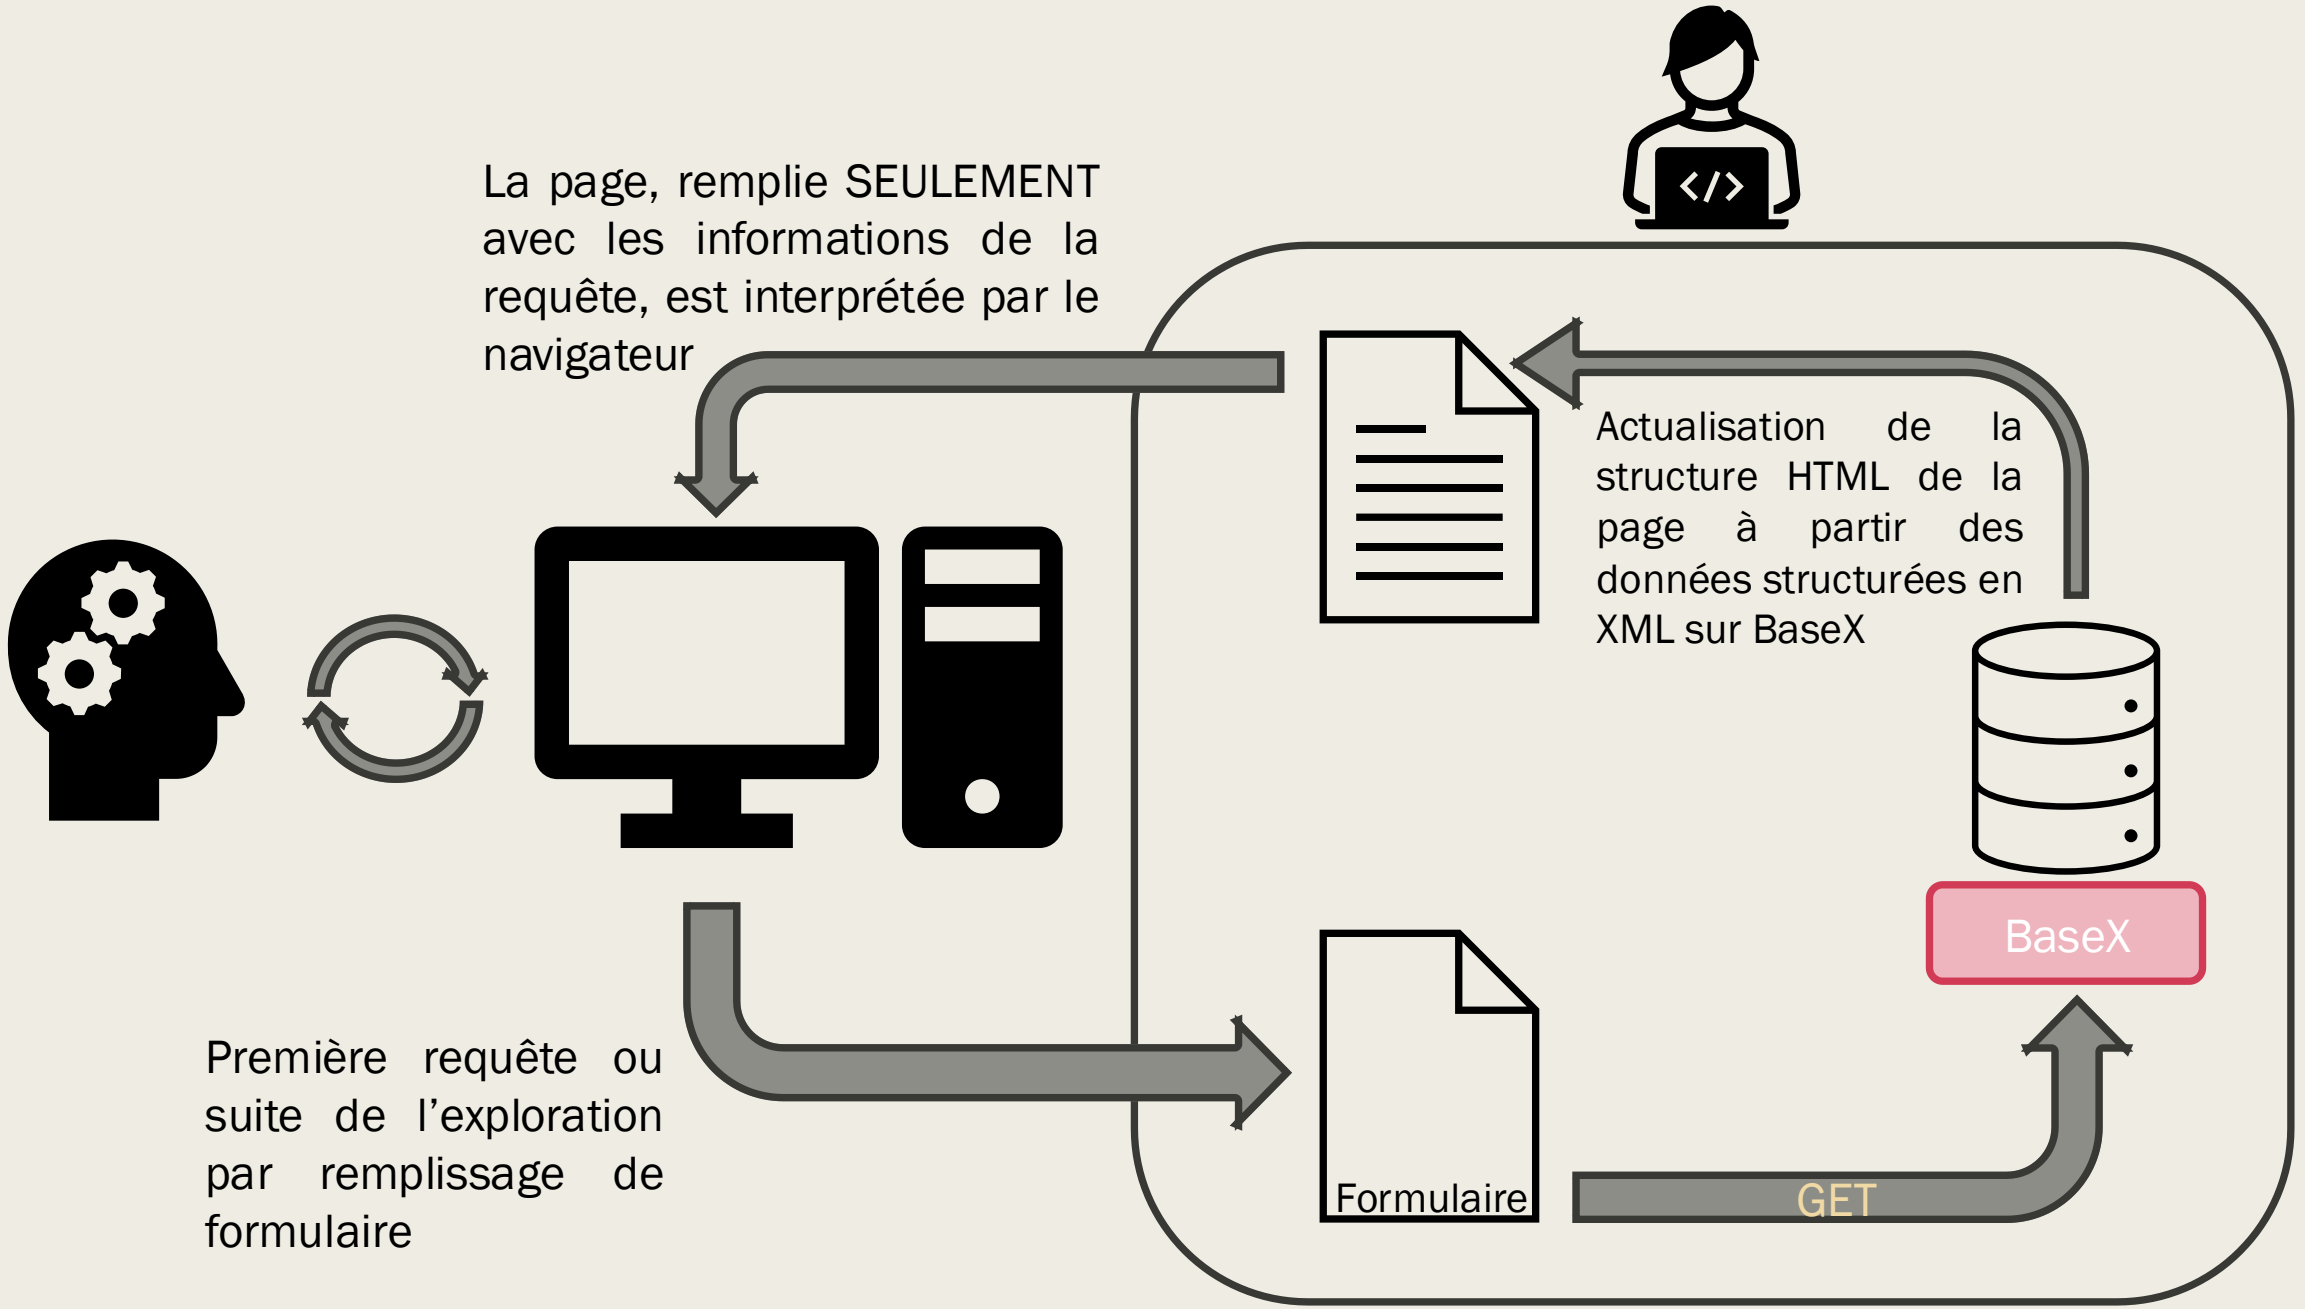
Conclusion sur la pratique : HTML statique ou dynamique ?

- Statique (fait aujourd'hui)
  - *Encodage qui transcrit une pensée parmi d'autres (applique une grille de lecture)*
  - *Jack Goody,* La raison graphique. La domestication de la pensée sauvage, *Jean Bazin (trad.), Alban Bensa (éd.), Paris, Minuit, 1979.*
  - *L'écrit est un mode de reproduction* ***d'un*** *système de pensée (il peut donc y en avoir d'autre)*
  - *Proche de la page classique donc de la* ***consultation simple***

Conclusion sur la pratique : HTML statique ou dynamique ?

- Dynamique
  - *Besoin technique d'un logiciel côté serveur (ici BaseX)*
  - *La page est « fabriquée » en fonction de la requête du lecteur (co-constructeur)*
  - *Michel Bernard et Baptiste Bohet*, Vers une nouvelle paginalité ? Essai sur les mutations de la page, *Carignan-de-Bordeaux, Le Bord de l'Eau, 2026.*
  - *Notion d'*egopage
    - *Le lecteur devient* ***explorateur*** *dans un espace construit par l'éditeur en construisant sa propre page suivant ses propres requêtes*

La page, remplie SEULEMENT avec les informations de la requête, est interprétée par le navigateur



Première requête ou suite de l'exploration par remplissage de formulaire

PARTIE 2

EXPLORER LES DONNÉES

NOTION D'ARBORESCENCE

Promenons-nous dans les bois



Qu’est-ce que l’arborescence ?

- Idée majeure en informatique
- Organisation des idées de manière hiérarchique de la racine de l’arbre jusqu’aux feuilles (les valeurs que les balises emballent)
- Un nœud enfant ne possède qu’un parent (hiérarchie par emboîtement) mais peut avoir des frères (partagent le même parent). Ce(s) dernier(s) peuvent à leur tour avoir des enfants (ils emboîtent une/plusieurs autre(s) balise(s)).
- Un enfant particulier ne possède qu’un chemin pour y arriver
  - *Un chemin peut mener à plusieurs à enfants*
  - *Ex. Une pièce de théâtre se compose de plusieurs actes, la division de l’acte 1 n’est accessible que par un chemin, mais sans plus de précision sur le chemin (acte 1 n’est alors pas un critère), ce même chemin mènera vers tous les actes car dans une pièce de théâtre tous les actes sont des éléments de même niveau (ils n’ont aucun lien de dépendance structurelle).*

Se déplacer dans l'arborescence avec XPath

- Langage de navigation par expression de chemins (avec des « / ») entre les branches
- **Chemin absolu** (à partir de la racine) : « /TEI/A/B/C/…/feuille cherchée »
- **Chemin relatif** (à partir de là où nous sommes déjà) : « //K/L/…/feuille cherchée » (il commence par un double slash « // »)
- Les fonctions : affiner et calculer des résultats
  - *Ex. « **count()** » : permet de mettre, entre ses parenthèses, une expression de chemin pour compter le nombre de résultats pour ce chemin-là (rappel : un chemin peut mener à plusieurs feuilles)*
- Les prédicats : ils se mettent [entre crochets] et permettent de filtrer les résultats en fonction de ce que l'on cherche.
  - *Ex. « div[@xml-id='p-HeretfilsLac'] » : renvoie tout ce que la balise emballe pour le chevalier Heret le fils de Lac.*
- Les attributs : les attributs XML se symbolisent par le « @ » présent devant le nom de l'attribut. Il peut être utilisé :
  - *Dans l'expression du chemin : « /@xml-id » ; pour renvoyer **la valeur contenue par l'attribut***
  - *Dans le prédicat « div[@xml-id='p-HeretfilsLac'] » ; pour vérifier la valeur de vérité exprimée (ici le chemin scanne toutes les et ne s'arrête que quand la valeur du prédicat est vérifiée (qui consiste ici en la comparaison de la valeur des attributs 'xml-id' à la valeur que l'on recherche.*

EXERCICE XPATH

Correction

- 1 : toutes les devises
  - *Relative : //q[@type='devise']*
  - *Absolue : /TEI/text/body/div[@type='quadrille']/div[@type='personnage']/q[@type='devise']*
- 2 : toutes les personnes
  - *//div[@type='personnage']/head*
  - */TEI/text/body/div[@type='quadrille']/div[@type='personnage']/head*
- 3 : description Louis XIV
  - *//div[@xml:id='p-roi']/p[@type='description']*
  - */TEI/text/body/div[@type='quadrille']/div[@xml:id='p-roi']/p[@type='description']*
- 4 : URL comte de Vivonne
  - *//div[@xml:id='p-vivonne']/figure/graphic/@url*
  - */TEI/text/body/div[@type='quadrille']/div[@xml:id='p-vivonne']/figure/graphic/@url*
- 5 : Nombre de participant dans la quadrille
  - *count (//div[@type='personnage'])*
  - *count(/TEI/text/body/div[@type='quadrille']/div[@type='personnage'])*

ANALYSER LES DONNÉES RELEVÉES

Exemple des *Estats et empires de la lune* de Cyrano de Bergerac
Encodé sur Frantext

Cyrano de Bergerac, *Les Estats et empires de la lune*

```
−<text>
 −<body>
    <pb n="5"/>
   −<p>
      <x:wf word="Les" pos="DET" lemma="le"/>
      <x:wf word="estats" pos="NC" lemma="état"/>
      <x:wf word="et" pos="CC" lemma="et"/>
      <x:wf word="empires" pos="NC" lemma="empire"/>
      <x:wf word="de" pos="P" lemma="de"/>
      <x:wf word="la" pos="DET" lemma="le"/>
      <x:wf word="lune" pos="NC" lemma="lune"/>
      <x:wf word="." pos="PONCT" lemma="."/>
      <lb/>
      <x:wf word="La" pos="DET" lemma="le"/>
      <x:wf word="lune" pos="NC" lemma="lune"/>
      <x:wf word="estoit" pos="V" lemma="être"/>
      <x:wf word="en" pos="P" lemma="en"/>
      <x:wf word="son" pos="DET" lemma="son"/>
      <x:wf word="plein" pos="NC" lemma="plein"/>
      <x:wf word="," pos="PONCT" lemma=","/>
      <x:wf word="le" pos="DET" lemma="le"/>
      <x:wf word="ciel" pos="NC" lemma="ciel"/>
      <x:wf word="estoit" pos="V" lemma="être"/>
      <lb/>
```

Cyrano de Bergerac, *Les Estats et empires de la lune*

TROIS NIVEAUX DE TEXTE

TOKEN	LES	ESTATS	ET	EMPIRES	DE	LA	LUNE	.
LEMME	LE	ÉTAT	ET	EMPIRE	DE	LE	LUNE	.
POS	DET	NC	CC	NC	P	DET	NC	PONCT

Tokeniser : Le texte est découpé en unités signifiantes en suivant un schéma de tokénisation (généralement grâce aux espaces, mais pas que !)

Lemmatiser : Associer au token son lemme : sa forme au (masculin) singulier

Tagger : Associer au token son *Part Of Speech* : sa catégorie grammaticale
Il est aussi possible d'ajouter un niveau MORPH : qui décrit la morphologie du token. (ex. MORPH pour « Estat » : MASC|PLU).

CONCLUSION

Conclusion

- Le numérique transforme radicalement notre rapport au texte, de l'édition à la consultation
- XML permet de structurer les documents pour aller dans ce sens
- L'enjeu des Humanités Numériques n'est pas seulement de rendre une source consultable (ce serait simplement de la numérisation) mais de produire de nouveaux outils d'analyse
- Le texte se trouve dans un état parallèle qui permet de faire dialoguer les analyses qualitatives avec d'autres outils mathématiques pour produire de nouvelles conclusions

```
<p>
  Merci pour
  votre attention
  et pour votre
  participation !
</p>
```



Pour me laisser votre avis